

Universidad del Valle de Guatemala  
Facultad de ingeniería



Data Science

Laboratorio 4

Comparacion de algoritmos de Series de Tiempo aplicados a diferentes tipos de conjuntos de  
datos

Jun Woo Lee  
Andres de la Roca

Guatemala, año

## Índice

<b>Índice.....</b>	<b>1</b>
<b>Introducción.....</b>	<b>1</b>
<b>Exploración de datos.....</b>	<b>1</b>
<b>Resultados.....</b>	<b>1</b>
<b>Discusión.....</b>	<b>1</b>
<b>Conclusiones.....</b>	<b>1</b>
<b>Referencias bibliográficas.....</b>	<b>1</b>

## Introducción

Para esta práctica se decidió analizar y realizar modelos a partir de ciertos conjuntos de datos, con el objetivo principal de obtener una sólida comprensión acerca de los algoritmos utilizados para realizar predicciones de series de tiempo y como aplicarlos de manera adecuada en función de las características intrínsecas de las series, como la tendencia y la estacionalidad. Para llevar a cabo esta práctica se emplearon diversas herramientas como Python con bibliotecas como pandas, numpy, matplotlib, sklearn, statsmodels, Prophet, etc. Asimismo, se utilizó el entorno de desarrollo de Jupyter Notebook para de cierta forma facilitar el desarrollo y visualización interactiva de los diferentes modelos y predicciones.

El enfoque metodológico se dividió en siete etapas fundamentales:

- **Análisis Exploratorio:** Se llevó a cabo una descripción detallada de cada serie de tiempo y se visualizaron para comprender sus características esenciales.
- **Promedios:** Se aplicaron métodos de promedios y se compararon los resultados con la serie original, lo que permitió evaluar la eficacia de este enfoque.
- **SARIMA:** Se identificaron los parámetros adecuados y se ajustaron modelos SARIMA (Seasonal Autoregressive Integrated Moving Average) para cada conjunto de datos.
- **Alisamiento Exponencial:** Se emplearon diversos métodos de alisamiento exponencial y se compararon sus resultados en términos de precisión predictiva.
- **Prophet:** Se utilizó la potente herramienta Prophet para modelar las series de tiempo y se evaluó su capacidad para realizar predicciones precisas.
- **Redes Neuronales:** Se implementaron redes neuronales simples con el objetivo de prever las series de tiempo y se evaluó su rendimiento en comparación con otros algoritmos.
- **Comparación y Evaluación:** Se utilizaron métricas de evaluación como RMSE (Root Mean Square Error) y MAE (Mean Absolute Error) para comparar y analizar en profundidad el rendimiento de los distintos modelos. Se discutió cuál algoritmo se desempeñó mejor para cada tipo de conjunto de datos y se proporcionaron razones fundamentadas para respaldar las conclusiones.

## Exploración de datos

Para la exploración de datos de esta práctica se crearon gráficas a partir de los conjuntos de datos dados para intentar observar algún tipo de patrón que pudiera ayudar en el desarrollo de los diferentes modelos de predicción.

Para el conjunto de datos ‘Daily Total Female Births’ se muestra la cantidad de nacimientos femeninos del año 1959, empezando desde enero y terminando en diciembre.




Fig. 1. Visualización de ‘Daily Total Female Births’

Como se observa en la figura 1, no se tiene un patrón definido para los nacimientos, y más bien se puede ver como la gráfica tiene un movimiento de valores bastante errático, por lo que esto de cierta forma podría representar que el predecir este conjunto de datos podría resultar complicado.

Por otro lado, en cuanto a la frecuencia de los nacimientos se puede observar en la figura 2, que la mayor acumulación de nacimientos está entre 35 y 45 nacimientos.

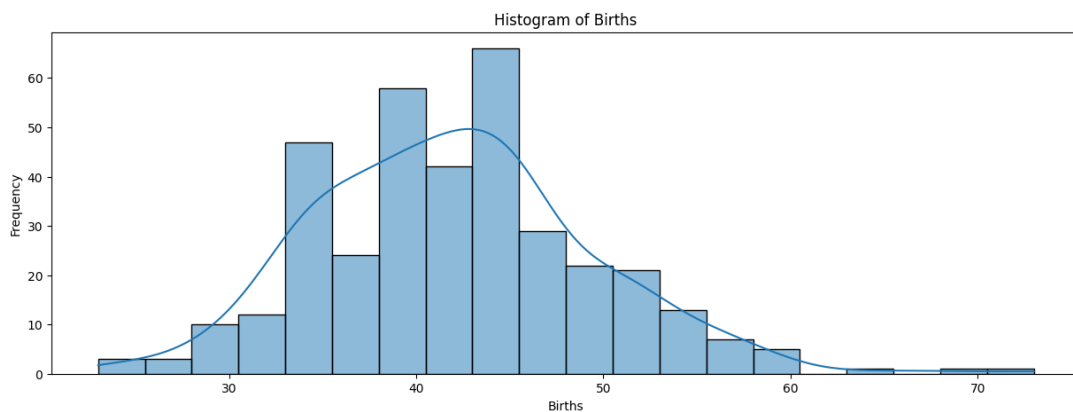


Fig. 2. Histograma de frecuencia de nacimientos

Este dato nos ayuda a ver un poco más el patrón que presenta este conjunto de datos, sin embargo, aún tiene valores algo erráticos entre la media que se puede observar.

Para el conjunto de datos ‘Shampoo’ se muestran las ventas de Shampoo de manera mensual, empezando desde enero y terminando en diciembre.

Como se puede observar en la figura 3, este conjunto de datos ya muestra una cierta tendencia en el crecimiento de las ventas con el paso del tiempo, obviamente se observan ciertos picos durante este ascenso, pero aún así la tendencia del crecimiento es clara.




Fig. 3. Visualización ‘Shampoo’

Esta tendencia observada puede dar una idea general de lo que se puede esperar de las predicciones con los modelos, un aumento mientras más pasa el tiempo.

En la figura 4, el histograma muestra como la cantidad de ventas en promedio se encuentra entre 100 y 400, pero aun se puede observar que debido al crecimiento ascendente los valores entre 500 y 700 van a ir creciendo con el paso del tiempo.

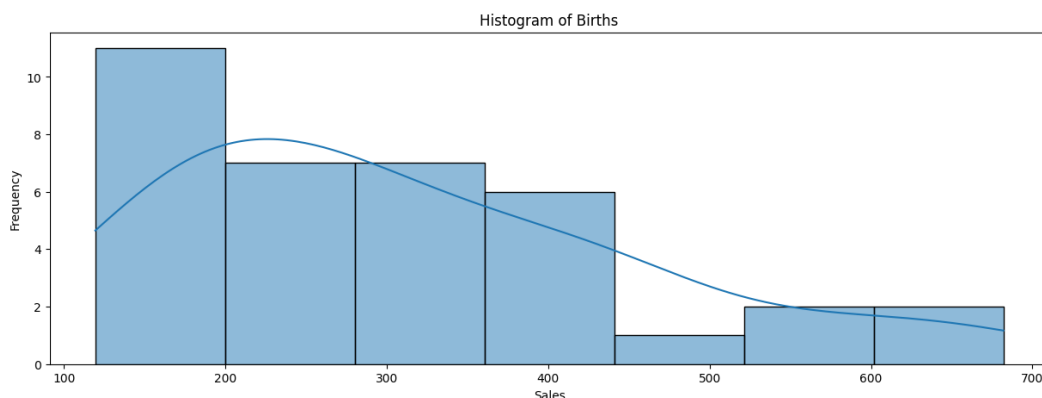


Fig. 4. Histograma de frecuencia de ventas de shampoo

Para el conjunto de datos “Monthly Mean Temp” se muestran las temperaturas promedio de cada mes.

Como se puede observar en la figura 5, este conjunto de datos muestra que la temperatura a través del año va oscilando




Fig. 5. Visualización ‘Monthly Mean Temperatures’

En la figura 6, el histograma muestra cómo las temperaturas están todas bien similares, con unas excepciones como en los treintas y en los cuarentas.




Fig. 6. Histograma de frecuencia de ventas de shampoo

Para el conjunto de datos “Monthly Car Sales” se muestran las ventas de carros promedias de cada mes.

Como se puede observar en la figura 7, este conjunto de datos muestra que los precios poco a poco muestran una tendencia de oscilación pero siempre el pico siendo más alto que el previo, mostrando una tendencia de crecer al pasar el tiempo.




Fig. 7. Visualización ‘Monthly Car Sales’

En la figura 8, el histograma muestra cómo el precio promedio de los carros es entre los 10mil y 15mil.




Fig. 8. Histograma de frecuencia de ventas de carros

## Resultados

### **Conjunto de nacimientos femeninos**

Para este conjunto de datos se está buscando el poder predecir la cantidad de nacimientos de acorde a la fecha, para realizar esto se utilizó una muestra de 100 elementos en total y estos fueron divididos en conjuntos de prueba y de entreno para todos los modelos.

- **Promedios**

Como se puede observar en la siguiente figura, los valores de predicciones se mantienen constantemente cerca del valor real de los nacimientos y solo se cuenta con un MSE de 7.89, lo que nos dice que el modelo es bastante preciso en sus predicciones.

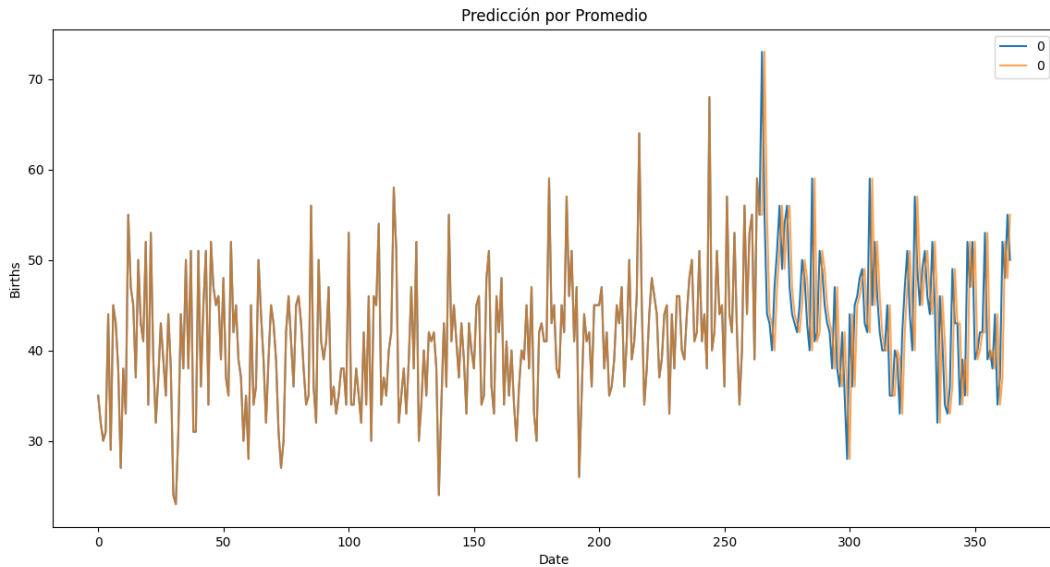


Fig. 9. Predicción por promedio - Nacimientos

- SARIMA

En el modelo de SARIMA se realizó una prueba dentro de una parte específica del conjunto para observar cómo se comporta dentro de esta y como se puede observar sigue las tendencias del conjunto con bastante exactitud, ofreciendo un MSE de tan solo 7.18.




Fig. 10. Predicción por SARIMA - Nacimientos

- Alisamiento Exponencial

Para este modelo se puede observar como la predicción mantiene un comportamiento bastante similar a como son los valores reales del conjunto, similar a los demás, este ofrece un valor de MSE de 7.35.






Fig. 11. Predicción por aislamiento - Nacimientos

- Prophet

En el modelo de Prophet se puede encontrar que es el modelo con mayor precisión de hasta el momento, con un MSE de 6.75, lo cual es una mejora notable sobre los demás modelos, adicionalmente, la gráfica que Prophet genera deja observar como podría ser una predicción más allá de lo que el conjunto tiene y su incertidumbre con el paso del tiempo.




Fig. . Predicción por Prophet - Nacimientos

- Redes neuronales

Para el modelo realizado con redes neuronales se tuvo una mayor precisión que la del modelo Prophet, con un MSE de 6.73, en la siguiente figura se reflejan las

predicciones que se tuvieron con este modelo y nos muestra su precisión y comportamiento que tuvo utilizando los datos del conjunto.




Fig. 12. Redes neuronales - Nacimientos

Modelo	Promedio	SARIMA	Alisamiento	Prophet	Redes
RMSE	7.89	7.18	7.35	6.75	6.73

Como se puede observar en general se obtuvo un mejor resultado en el Prophet y en las redes neuronales que en los demás modelos, esto posiblemente se deba a la naturaleza de estos en los que pueden encontrar ciertos patrones clave que puede utilizar para sus predicciones, a diferencia de los otros tres. Sin embargo, si se utilizara alguno para realizar predicciones a largo plazo, el modelo Prophet sería el ideal, debido a que toma mucho menos tiempo que los demás modelos, ya que realiza su entrenamiento en tan solo 4 segundos, mientras que los demás lo realizan entre 20 y 40 segundos aproximadamente.

### Conjunto de ventas de shampoo

Para este conjunto de datos se está buscando el poder predecir la cantidad de ventas según pasan los meses. Se utiliza un tamaño de muestra de 35 para realizar las pruebas.

- Promedios

Para la predicción por medio de promedios se observa un MSE de 108.23, lo cual tomando en cuenta los valores del conjunto se le podría considerar medianamente preciso, pero seguramente con los demás modelos esto puede mejorar.




Fig. 13. Predicción por promedio - Ventas shampoo

- SARIMA

En el modelo de SARIMA se encontró una mejora considerable del MSE, llegando hasta 60.03, lo cual a comparación del método de promedios es mucho más bajo, haciéndolo más preciso.




Fig. 14. Predicción por SARIMA - Ventas shampoo

- Alisamiento Exponencial

Para el modelo de alisamiento se puede observar que se tiene una menor precisión que en el modelo anterior, principalmente en cuanto comienzan a aumentar la cantidad de ventas de shampoo.

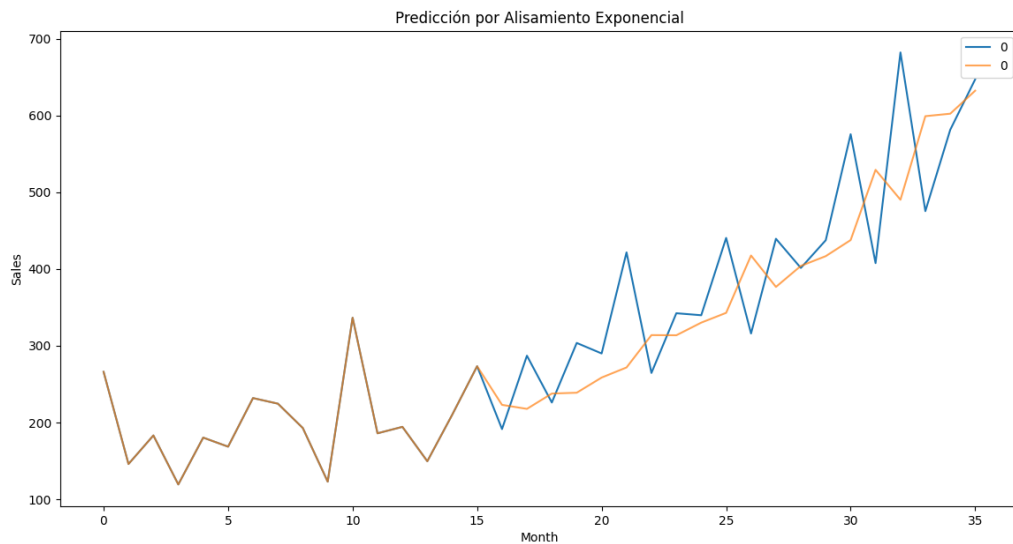


Fig. 15. Predicción por aislamiento - Ventas shampoo

- Prophet

En el modelo de Prophet se obtuvo un MSE de 112.90, lo cual es considerablemente alto, esto quizás se deba a que el modelo funciona mejor cuando tiene una mayor cantidad de datos.




Fig. 16. Predicción por Prophet - Ventas shampoo

- Redes neuronales

Para el modelo de redes neuronales se obtuvo un MSE de 109.54, se puede observar en la siguiente figura, como en cierto momento cuando empieza a aumentar la cantidad de ventas la predicción se empieza a separar bastante de los valores reales, lo que pudo causar esta imprecisión.




Fig. 17. Redes neuronales - Nacimientos

Modelo	Promedio	SARIMA	Alisamiento	Prophet	Redes
RMSE	108.23	60.03	85.83	112.90	109.54

Entre los resultados encontrados se podría elegir al de alisamiento exponencial como el más eficiente y preciso, y que cuenta con un MSE relativamente bajo además de que su entrenamiento toma menos de un segundo, a diferencia del modelo de SARIMA, que toma aproximadamente unos 36 segundos en entrenarse.

### Conjunto de temperatura

Para este conjunto de datos se está buscando el poder predecir la temperatura de un mes, para realizar esto se utilizó una muestra de 241 elementos en total y estos fueron divididos en conjuntos de prueba y de entreno para todos los modelos.

- Promedios

Como se puede observar en la siguiente figura, los valores de predicciones se mantienen constantemente cerca del valor real de las temperaturas y solo se cuenta con un MSE de 5.14, lo que nos dice que el modelo es bastante preciso en sus predicciones.

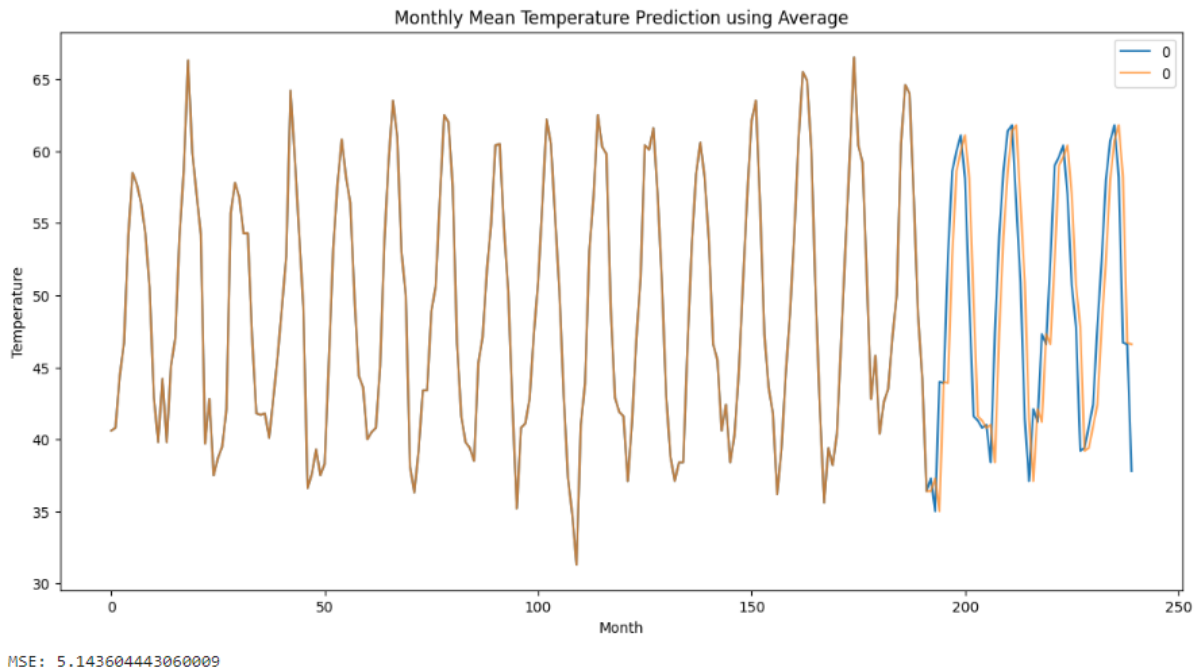


Fig. 18. Prediccion por promedio - Temperaturas

- SARIMA

En el modelo de SARIMA se realizó una prueba dentro de una parte específica del conjunto para observar cómo se comporta dentro de esta y como se puede observar este modelo no obtuvo los mejores resultados con un MSE de 18.71

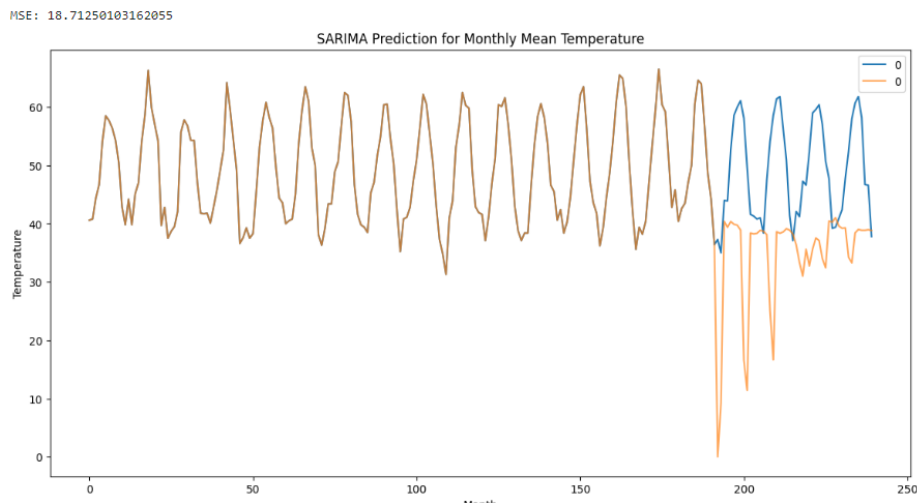


Fig. 19. Predicción por SARIMA- Temperaturas

- Alisamiento Exponencial

Para este modelo se puede observar como la predicción mantiene un comportamiento bastante similar a como son los valores reales del conjunto, similar a los demás, este ofrece un valor de MSE de 4.55.

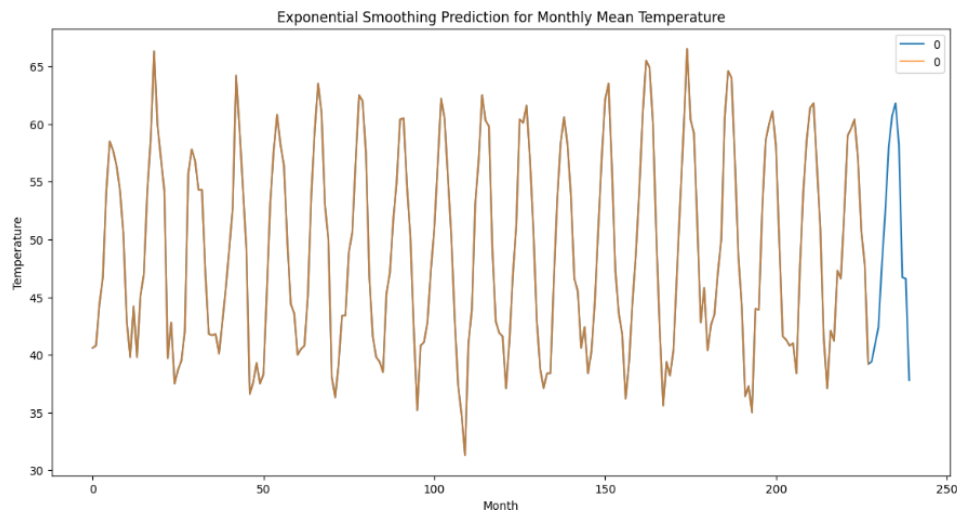


Fig. 20. Predicción por aislamiento - Temperaturas

- Prophet

En el modelo de Prophet se puede encontrar que es el modelo con mayor precisión de hasta el momento, con un MSE de 2.16, lo cual es una mejora notable sobre los demás modelos, adicionalmente, la gráfica que Prophet genera deja observar como podría ser una predicción más allá de lo que el conjunto tiene y su incertidumbre con el paso del tiempo.

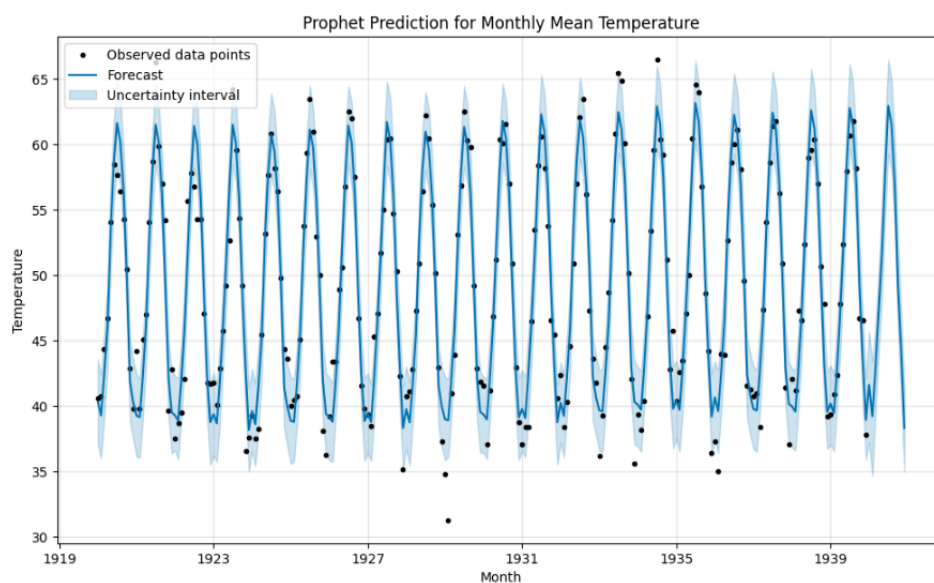


Fig. 21. Predicción por Prophet - Temperaturas

- Redes neuronales

Para el modelo realizado con redes neuronales se tuvo una mayor precisión que la del modelo Prophet, con un 2.459 RMSE (+/- 0.076), en la siguiente figura se reflejan las predicciones que se tuvieron con este modelo y nos muestra su precisión y comportamiento que tuvo utilizando los datos del conjunto.




Fig. 22. Redes neuronales - Temperaturas

Modelo	Promedio	SARIMA	Alisamiento	Prophet	Redes
RMSE	5.14	18.71	4.55	2.16	2.46

Entre los resultados encontrados se podría elegir al de prophet como el más eficiente y preciso, y que cuenta con un MSE relativamente bajo comparado a los otros modelos. Donde el de redes neuronales es un poco peor.

### Conjunto de ventas de carros

Para este conjunto de datos se está buscando el poder predecir la cantidad de ventas según pasan los meses. Se utiliza un tamaño de muestra de 109 para realizar las pruebas.

- Promedios

Para la predicción por medio de promedios se observa un MSE de 3783.97, lo cual tomando en cuenta los valores del conjunto se le podría considerar medianamente preciso, pero seguramente con los demás modelos esto puede mejorar.

MSE: 3783.9662392785694

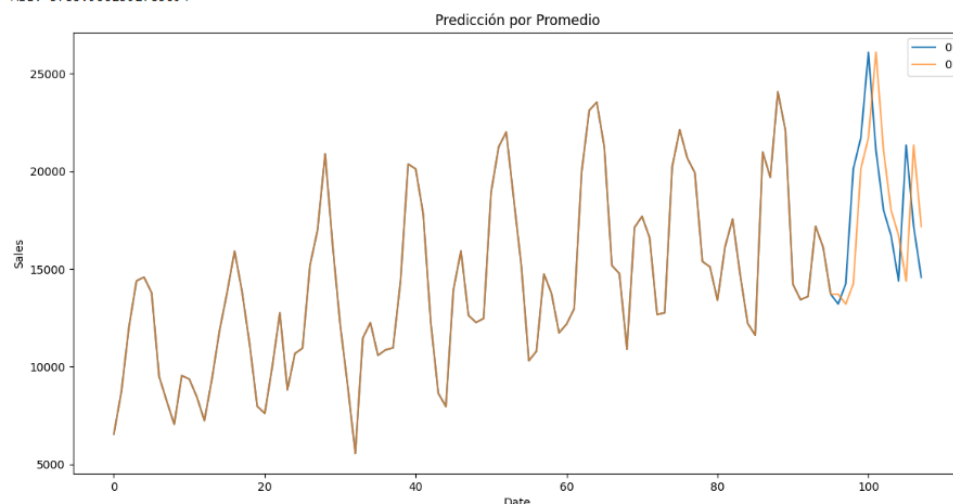




Fig. 23. Predicción por promedio - Ventas carros

- SARIMA

En el modelo de SARIMA se encontró una mejora considerable del MSE, llegando hasta 1891.69, lo cual a comparación del método de promedios es mucho más bajo, haciéndolo más preciso.

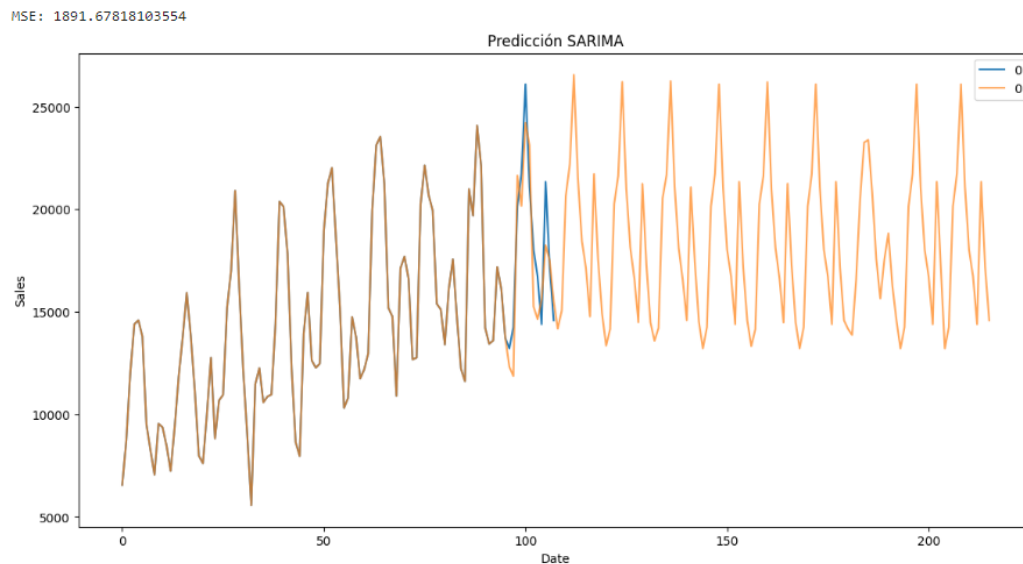


Fig. 24. Predicción por SARIMA - Ventas carros

- Alisamiento Exponencial

Para el modelo de alisamiento se puede observar que se tiene una menor precisión que en los modelos previos, principalmente que el comportamiento no se logra simular de la misma manera y que el mse llega casi a 10000, que sería algo como una variación de 100 dólares de una venta. Que con los valores de los carros no es tan grande.

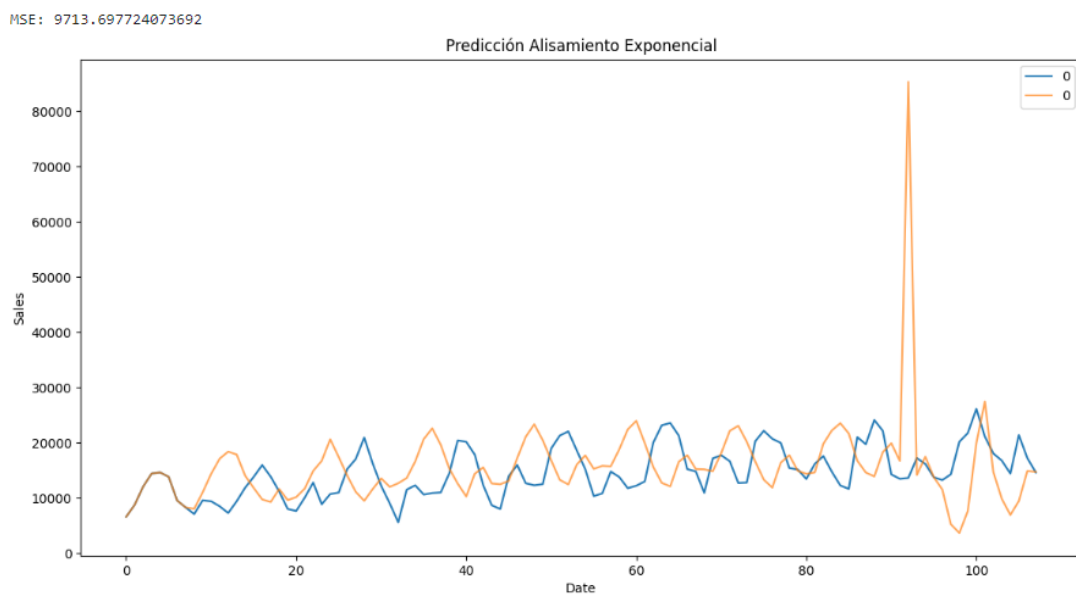


Fig. 25. Predicción por aislamiento - Ventas carros

- Prophet

En el modelo de Prophet se obtuvo un MSE de 1298.46, lo cual es considerablemente bajo, teniendo un mejor resultado que el de SARIMA.




Fig. 26. Predicción por Prophet - Ventas carros

- Redes neuronales

Para el modelo de redes neuronales se obtuvo un 1998.280 RMSE (+/- 57.837), se puede observar en la siguiente figura, como en cierto momento cuando empieza a aumentar la cantidad de ventas la predicción sigue manteniendo el mismo patron.




Fig. 27. Redes neuronales - Ventas carros

Modelo	Promedio	SARIMA	Alisamiento	Prophet	Redes
RMSE	3783.97	1891.68	9713.7	1298.46	1998.28

Para este conjunto de datos, el modelo con mejor rendimiento también fue el de prophet, donde el de SARIMA y el de redes funcionaron de forma similar. Mientras que el de alisamiento fue el peor.

### Discusión

Después del análisis de datos y de resultados se puede decir que cada uno de los modelos tiene sus ventajas y desventajas, cada uno se adapta de una manera diferente a cada uno de los datos obtenidos, por lo que es importante elegir el correcto para el caso de uso en el que se vaya a utilizar.

Los métodos de promedios son un enfoque simple para el análisis de las series de tiempo, ya que más que nada sus predicciones suavizan las fluctuaciones aleatorias que encuentra en el conjunto y resalta las tendencias ya encontradas, pero si se llegara a encontrar con patrones complejos o con conjuntos con estacionalidad pronunciada puede llegar a ser impreciso.

Los modelos SARIMA es un paso más arriba en cuanto a complejidad, ya que tiene en cuenta la autocorrelación de la serie de tiempo así como la estacionalidad, se ha visto en los resultados que puede resultar un enfoque efectivo cuando se quiere modelar series de tiempo con patrones estacionales y patrones bien definidos.

En cuanto al alisamiento exponencial se podría decir que son de cierta manera similares a los métodos de promedio, ya que intenta suavizar las series de tiempo y realizar predicciones a corto plazo, debido a que es fácil de implementar y se puede utilizar para patrones menos complejos como se observa en el modelo realizado para la venta de shampoo, todo esto con un bajo costo en cuanto a recursos.

Por otro lado, los modelos Prophet, tiene una amplia variedad de aplicaciones, tiene la capacidad de manejar series de tiempo que tengan estacionalidad y días festivos, adicionalmente, es muy fácil de implementar, ya que las implementaciones realizadas para los conjuntos de datos estudiados son bastantes simples en cuanto a su contenido.

Las redes neuronales permiten capturar patrones altamente complejos de las series de tiempo debido a cómo trabajan sus neuronas, lo que automáticamente lo hace una elección muy atractiva para este caso de uso, sin embargo, su rendimiento depende a menudo de la cantidad de datos disponibles, esto se ve especialmente reflejado en la diferencia en la precisión del conjunto de datos de venta de shampoo y el de nacimientos femeninos, ya que el de venta de shampoo contiene una menor cantidad de datos, por lo que se le hizo más difícil al modelo observar algún tipo de patrón y por esta razón no pudo ser tan preciso como con el otro conjunto.

## Conclusiones

- Los modelos de alisamiento exponencial son especialmente útiles cuando se tiene una cantidad baja de datos
- Los modelos de Prophet son bastante robustos debido a todas las opciones que tiene para poder modificar para adaptarlo al caso de uso específico que se necesite.
- Las redes neuronales necesitan de una cantidad considerable de datos para ser precisos y reconocer patrones en las series de tiempo.
- El tamaño del conjunto de datos influye significativamente en el desempeño del modelo.
- Si bien el desempeño del modelo es crucial, también lo es la eficiencia en términos de recursos y tiempo.
- No todos los modelos tienen la misma tolerancia al ruido y outliers. Modelos robustos que puedan manejar estos aspectos son a menudo más útiles en aplicaciones del mundo real.

## Referencias bibliográficas

Peixeiro, M. (2023) The Complete Guide to Time Series Models. Extraído de [Builtin](#)

Dix, P. (2020) Time Series Forecasting Methods. Extraído de [InfluxData](#)

Taylor, S. J., & Letham, B. (2018). Forecasting at scale. The American Statistician, 72(1), 37–45.

Shumway, R. H. (1988). Applied statistical time series analysis. Englewood Cliffs, NJ: Prentice Hall.